Влияние трансформаций временного ряда на качество глобальных ML-моделей

TS AI HSE 2026 · Проект

Валеева Лейсан Нурмухаметовна

1. Постановка задачи и гипотеза

Цель исследования — определить, какие преобразования ряда полезны для разных типов временных рядов при использовании глобальной модели машинного обучения. В качестве глобальной модели выбран CatBoost, сравниваемые трансформации: **log1p**, **boxcox** и **diff**.

Гипотеза: разные трансформации дают разный эффект в зависимости от статистического характера ряда — тренда, волатильности, асимметрии распределения. Для проверки ряды сначала кластеризуются по статистическим признакам, после чего метрики качества оцениваются отдельно по каждому кластеру.

Задачи:

1. Кластеризация выборки M4 Monthly; подбор числа кластеров по силуэтному коэффициенту.
2. Бейзлайны: Naive, SeasonalNaive, Mean, Median, AutoTheta, AutoETS.
3. Обучение одной глобальной модели CatBoost (Direct-стратегия, 18 горизонт).
4. Сравнение четырёх трансформаций — глобально и отдельно по каждому кластеру.
5. Формулировка выводов: для каких типов рядов какая трансформация полезна.

---

2. Описание данных

Использовалась выборка из 200 временных рядов датасета **M4 (Monthly)**. Минимальная длина ряда — 60 месяцев, средняя длина обучающей части — 221 шаг. Горизонт прогноза — **18 шагов** (1,5 года). Все метрики вычислялись в исходной шкале после корректного применения обратных трансформаций.

---

3. Методология

3.1. Кластеризация

Ряды кластеризовались методом KMeans по шести статистическим признакам: среднее, стандартное отклонение, коэффициент вариации, асимметрия, эксцесс и коэффициент линейного тренда. Признаки нормировались StandardScaler. Число кластеров k подбиралось автоматически перебором k = 3…8 с выбором максимума силуэтного коэффициента. Оптимальным оказалось **k = 4**

Кластер	n	CV	Тренд	Эксцесс	Описание
0	138	0.20	+2.3	−0.25	Стабильные, нет тренда
1	40	0.56	+34.5	+0.43	Растущие
2	19	0.36	−70.2	−0.62	Сильный нисходящий тренд
3	3	0.82	+6.4	+36.78	Экстремальные выбросы.

> Кластер 0 составляет 69% выборки. Кластер 3 содержит всего 3 ряда; выводы по нему носят не статистически значимый характер, а иллюстративный

3.2. Модели

Бейзлайны: Naive, SeasonalNaive, Mean, Median (для проверки аномалии boxcox).

Статистические авто-модели: AutoTheta и AutoETS

CatBoost (глобальная модель): Ключевое:

- **Direct-стратегия** — 18 независимых моделей, нет рекурсии и накопления ошибки.
- **Нормализация рядов** (SeriesScaler) — без неё глобальная модель доминируется рядами с большими абсолютными значениями.
- **Метапризнаки ряда** (CV, тренд, эксцесс, номер кластера) добавляются как статические признаки к каждой строке.
- **`cat_features`**: `meta_cluster` и `month_in_period` передаются явно в CatBoost, что позволяет строить корректные статистики вместо числовых сплитов.

3.3. Признаки

- Лаги: 1–18, 24, 36
- Скользящие (mean, std, min, max) по окнам 3, 6, 12 — с lag-1 сдвигом (чтобы без утечки данных)
- Трендовые: t, t^2
- Сезонные: sin/cos Фурье 1-й и 2-й гармоник
- Метапризнаки ряда: `meta_mean`, `meta_std`, `meta_cv`, `meta_skew`, `meta_kurt`, `meta_trend`, `meta_cluster`

3.4. Метрики

Оценка по MAE, RMSE, MAPE, sMAPE и MASE. Ключевая метрика — **MASE** (Mean Absolute Scaled Error): метрика корректно агрегируется по рядам разного масштаба. Все метрики считались в исходной шкале.

---

4. Результаты

4.1. Глобальные метрики

Трансформация	Модель	MAE	RMSE	sMAPE	MASE
none	Naive	602.96	743.57	13.53	1.228
none	SeasonalNaive	629.10	765.03	14.73	1.266
none	AutoETS	513.25	643.49	11.83	**0.923**
none	AutoTheta	516.35	636.48	12.10	0.981
none	CatBoost	670.47	809.23	14.78	1.489
log1p	CatBoost	635.93	776.00	14.21	1.448
boxcox	CatBoost	1189.20	1351.73	36.21	4.029
diff	**CatBoost**	**516.63**	**633.83**	**12.36**	**1.002**

Без трансформации CatBoost (MASE = 1.489) уступает даже простому Naive (1.228). Это ожидаемый результат для глобальных моделей при малом наборе данных: без предобработки модель не способна экстраполировать тренд и теряется на ольшом горизонте. Трансформация `diff` кардинально меняет ситуацию: (MASE = 1.002) вплотную приближается к AutoTheta (0.981).

4.2. Метрики по кластерам — трансформация diff

Кластер	n	Тип	Naive	AutoTheta	AutoETS	CatBoost+diff	Итог
0	138	Стабильные	1.250	0.974	0.909	0.990	AutoETS лучше
1	40	Растущие	1.429	1.162	1.067	1.195	AutoETS лучше
2	19	Нисх. тренд	0.693	0.708	0.711	**0.673**	⋆ CatBoost лучше!
3	3	Выбросы (none)	0.968	0.625	0.981	1.068	AutoTheta лучше

Ключевое — кластер 2 CatBoost+diff (MASE = 0.673) превзошёл AutoTheta (0.708) и AutoETS (0.711). Это единственный кластер, где глобальная ML-модель победила локальные статистические. Сильный тренд — наиболее предсказуемый паттерн для модели, обученной на diff.

4.3. Лучшая трансформация по кластерам

Кластер	n	Лучшая (MASE)	Лучшая (sMAPE)	MASE
0	138	diff	diff	0.990
1	40	diff	diff	1.195
2	19	diff	diff	0.673
3	3	none	none	0.592

4.4. Анализ каждой трансформации

`diff` — лучшая трансформация для 3 из 4 кластеров

Дифференцирование устраняет нестационарность: модель предсказывает не абсолютный уровень. Это критично для деревьев: в отличие от линейных моделей, дерево не экстраполирует тренд — оно интерполирует между примерами из обучения. В пространстве приращений динамика рядов с разными уровнями становится сопоставимой, и глобальная модель легче выучивает паттерны между рядами.

`log1p` — малозаметный эффект

MASE улучшился с 1.489 до 1.448 — разница минимальна. Вообще считается что логарифмирование полезно, когда дисперсия шума растёт пропорционально уровню ряда. Однако SeriesScaler уже нормализует масштаб каждого ряда перед обучением, частично решая ту же проблему (без scaler catboost совсем плхо себя чувствует на таком малом наборе семплов). Поэтому `log1p` не даёт дополнительного выигрыша — уровень масштабирования уже учтён. Однако в отсутствии скейлинга эффект бы наблюдался

`boxcox` — стабильно вреден

Причина не в нестабильной оценке лямбды, а в нелинейности обратного преобразования. Функция `inv_boxcox(z, λ)` при $\lambda > 0$ имеет вид `x = (z·λ + 1)^(1/λ)` — это степенной рост. Даже небольшое отклонение предсказания от реального значения в Box-Cox-пространстве приводит к непропорционально большой ошибке в исходной шкале. Для кластера 0 MASE = 4.97 — модель уступает даже среднему значению. Это ограничение применения `boxcox` с ML-моделями, нужна сложная предобработка **`none` — нужен только для аномальных рядов**

При экстремальных выбросах `diff` усиливает их амплитуду (разность между нормальным значением и выбросом вдвое больше самого выброса), `log1p` сжимает недостаточно, а `boxcox` взрывается при обратном преобразовании. Деревья CatBoost устойчивы к выбросам, поэтому исходные данные оказываются предпочтительными. Однако выборка в 3 ряда не позволяет делать статистически значимых выводов.

---

5. Выводы

Гипотеза подтверждается частично. Разные типы рядов действительно требуют разных трансформаций, хотя `diff` доминирует в большинстве кластеров в данном наборе данных.

1. **`diff` — наиболее универсальная трансформация** для CatBoost на M4 Monthly. Работает в 3 из 4 кластеров.

2. **Для рядов с экстремальными выбросами** (kurt > 30) лучше не применять никакую трансформацию. `diff` усиливает амплитуду выбросов, `boxcox` взрывается при инверсии.

3. **`log1p` практически не помогает** при наличии нормализации рядов (SeriesScaler). Его следует рассматривать как альтернативу нормализации, но точно не как дополнение к ней.

4. **`boxcox` не рекомендуется** для использования с CatBoost в данной задаче. Нелинейность `inv_boxcox` непропорционально усиливает ошибки прогнозирования при восстановлении в исходную шкалу.

5. **Локальные статистические модели** (AutoETS, AutoTheta) превосходят глобальный CatBoost в большинстве кластеров. Разрыв минимален для трендовых кластеров и максимален для стабильных. Потенциал глобальных моделей сложно увидеть при малом числе рядов.